

Identyfikacja minerałów z wykorzystaniem przetwarzania obrazów i klasyfikacji

Analiza danych multimedialnych

Autorzy: Jan Hordyński, Krzysztof Łaczmański

Prowadzący: dr inż. Łukasz Jeleń

Grupa zajęciowa: SOTS_M_I_NWh_INF_SliUM_1m_lab

Data: 01.02.2026

1. Wstęp

Celem niniejszego projektu było zaprojektowanie i zaimplementowanie systemu komputerowego służącego do automatycznego wstępnego przetwarzania (preprocessingu) oraz identyfikacji próbek minerałów na podstawie zdjęć.

System wykorzystuje bibliotekę OpenCV do manipulacji obrazem oraz metody statystyczne do ekstrakcji cech. Głównym zadaniem aplikacji jest odizolowanie obiektu od tła, normalizacja jego wyglądu oraz przypisanie go do jednej ze zdefiniowanych klas (typów minerałów) na podstawie analizy koloru, tekstury i kształtu. Projekt ma na celu zweryfikowanie skuteczności klasycznych metod wizji komputerowej w zadaniu rozpoznawania obiektów naturalnych o nieregularnych kształtach przy ograniczonym zbiorze danych treningowych.

2. Opis danych

Zbiór danych wykorzystany w projekcie składa się z autorskich fotografii minerałów wykonanych przez członków zespołu.

- **Charakterystyka zbioru:** Baza składa się z 6 klas minerałów: kwarc, kwarc dymny, siarka, obsydian, argonit i cytryn.
- **Liczliwość:** Każda klasa reprezentowana jest przez około 15–20 zdjęć.
- **Warunki akwizycji:** Zdjęcia zostały wykonane na jasnym, jednolitym tle, co jest kluczowe dla zastosowanego algorytmu segmentacji (kod zakłada tło o jasności > 240 w skali szarości).
- **Zróżnicowanie:** Próbki fotografowane pod różnymi kątami, jednak przy staraniach o zachowanie zbliżonych warunków oświetleniowych dla części zbioru treningowego.
- **Oświetlenie:** Do oświetlenia próbek została użyta latarka, której światło padało z góry pod kątem 90 stopni do podłoża. Pozostałe światło zostało wyeliminowane

3. Opis i implementacja metod

System został podzielony na dwa główne moduły: UniversalMineralPreprocessor (odpowiedzialny za przygotowanie obrazu) oraz StatisticalMineralClassifier (odpowiedzialny za ekstrakcję cech i klasyfikację).

3.1. Preprocessing (Wstępne przetwarzanie obrazu)

Proces przygotowania zdjęcia składa się z 7 kroków sekwencyjnych. Celem jest usunięcie zakłóceń i wyodrębnienie minerału.

1. **Wczytanie obrazu:** Konwersja pliku graficznego do macierzy BGR.
2. **Odszumianie (Denoising):** Zastosowano filtr bilateralny (`cv2.bilateralFilter`). Metoda ta pozwala na wygładzenie obrazu i redukcję szumu matrycy, zachowując ostre krawędzie minerału, co jest kluczowe dla późniejszej segmentacji.
3. **Poprawa kontrastu (Enhancement):** Wykorzystano algorytm CLAHE (Contrast Limited Adaptive Histogram Equalization) na kanale jasności (L) w przestrzeni barw LAB. Pozwala to na wydobycie detali tekstury zarówno w jasnych, jak i ciemnych partiach kamienia.
4. **Segmentacja (Segmentation):** progowanie adaptacyjnego (`cv2.adaptiveThreshold`). Metoda ta radzi sobie z nierównomiernym oświetleniem, wyznaczając próg binaryzacji lokalnie dla każdego obszaru zdjęcia.
5. **Usuwanie artefaktów:** Zastosowano operacje morfologiczne (otwarcie i zamknięcie), aby usunąć drobne błędy oraz wygładzić krawędzie maski.
6. **Ekstrakcja (Extraction):** Wycięcie fragmentu zdjęcia zawierającego największy kontur zdefiniowany przez maskę, z dodaniem marginesu bezpieczeństwa.
7. **Normalizacja:** Skalowanie wyciętego minerału tak, aby zmieścił się w oknie 512x512 pikseli, z zachowaniem proporcji i uzupełnieniem tła kolorem białym. Gwarantuje to, że każde zdjęcie trafiające do klasyfikatora ma identyczne wymiary.

3.2. Ekstrakcja cech i klasyfikacja

Moduł StatisticalMineralClassifier opiera swoje działanie na wektorze cech (podpisie cyfrowym) każdego zdjęcia.

Wektor cech składa się z 5 wartości:

1. **Średni odcień (Hue):** Dominująca barwa minerału.
2. **Średnie nasycenie (Saturation):** Intensywność koloru.
3. **Średnia jasność (Value):** Jasność obiektu.
4. **Szorstkość (Roughness):** Obliczana jako odchylenie standardowe jasności pikseli wewnętrz maski obiektu – pozwala odróżnić gładkie minerały (np. obsydian) od chropowatych (np. Siarka).
5. **Współczynnik kształtu (Aspect Ratio):** Stosunek szerokości do wysokości prostokąta otaczającego obiekt.

Algorytm klasyfikacji: System działa na zasadzie klasyfikatora **Najbliższego Centroidu**.

1. **Trenig:** Dla każdego folderu (klasy minerału) obliczany jest "profil wzorcowy", będący średnią arytmetyczną wektorów cech wszystkich zdjęć w danym folderze.
2. **Predykcja:** Dla nowego zdjęcia obliczany jest jego wektor cech, a następnie mierzona jest odległość euklidesowa do wszystkich profili wzorcowych. Zdjęcie jest przypisywane do klasy, dla której odległość ta jest najmniejsza.

4. Wyniki

Testy systemu przeprowadzono na zbiorze walidacyjnym (zdjęcia niebiorące udziału w tworzeniu profilu średniego).

- **Wizualizacja:** Algorytm skutecznie izoluje minerał od tła, nawet przy obecności cieni rzucanych przez obiekt (dzięki zastosowaniu progowania adaptacyjnego i morfologii).
- **Skuteczność identyfikacji:**
 - W przypadku zdjęć wykonanych w warunkach oświetleniowych zbliżonych do zbioru treningowego (stała temperatura barwowa światła, podobny kąt padania), system osiągał bardzo wysoką skuteczność poprawnej identyfikacji.
 - W przypadku zdjęć wykonanych w drastycznie innym oświetleniu (np. światło dzienne vs sztuczne żółte światło), skuteczność systemu znaczco spadała i system rozpoznawał kawałek minerału jako osobny obiekt.

5. Dyskusja wyników

Zaobserwowana rozbieżność w wynikach (sukces przy stałym oświetleniu, porażka przy zmiennym) wynika bezpośrednio z zastosowanych metod:

1. **Wrażliwość modelu barwnego HSV:** Klasifikator opiera 3 z 5 swoich cech na kolorze. Zmiana oświetlenia (balansu bieli) aparatu powoduje drastyczne przesunięcie wartości wektora cech, nawet jeśli ludzkie oko wciąż rozpoznaje ten sam minerał.
2. **Mały zbiór danych:** Posiadanie jedynie 15-20 zdjęć na klasę powoduje zjawisko nadmiernego dopasowania (overfitting) do konkretnych warunków sesji zdjęciowej. Profil wzorcowy nie jest uśrednieniem "ogólnego wyglądu minerału", lecz "wyglądu minerału w tym konkretnym środowisku".
3. **Prosta statystyka:** Zastosowanie średniej (centroidu) jako wzorca jest skuteczne tylko wtedy, gdy dane są dobrze skupione (mała wariancja wewnętrzklasowa). Przy małej liczbie próbek jeden "dziwny" odblask lub cień może zafałszować cały profil wzorcowy klasy.
4. **Tło:** Algorytm w obecnej formie (`mask = gray < 240`) jest silnie uzależniony od bardzo jasnego tła. Zmiana tła na ciemniejsze powoduje błędna segmentację i włączenie tła do obliczeń koloru, co utrudnia klasyfikacje.

6. Podsumowanie i wnioski

Zrealizowany projekt pozwolił na stworzenie funkcjonalnego prototypu systemu do identyfikacji minerałów. Zastosowany potok przetwarzania skutecznie normalizuje zdjęcia, usuwając szумy i poprawiając kontrast, co zostało potwierdzone wizualnie.

Wnioski końcowe:

1. Metody klasycznej wizji komputerowej (filtry, morfologia) są bardzo skuteczne i szybkie w zadaniach preprocessingu i segmentacji, pod warunkiem zachowania kontrolowanych warunków oświetleniowych.
2. Klasyfikator oparty na prostych cechach statystycznych (kolor, tekstura) jest wystarczający dla małej liczby klas, ale wykazuje niską odporność na zmiany warunków środowiskowych (głównie światła).
3. **Możliwości rozwoju:** Aby system był odporny na błędy w warunkach rzeczywistych, należałyby:
 - a. Znaczaco powiększyć bazę danych.
 - b. Wprowadzić normalizację kolorów (np. algorytm Gray World) przed ekstrakcją cech.
 - c. Dalsze ulepszanie algorytmu oznaczającego maskę, by umożliwić rozbudowanie bazy danych o zdjęcia spoza ustalonego środowiska